Rapport de Business Understanding

Détection d'Anomalies Routières pour Véhicules Autonomes

Alignement Méthodologique CRISP-DM, Analyse du Dataset RoadAnomaly et État de l'Art

Module Deep Learning — Master Data Science / IA

Octobre 2026 — Date de rendu : 8 Novembre 2026

Abstract

Ce rapport formalise la première phase de la méthodologie standard **CRISP-DM** (*Business Understanding*) appliquée au projet de détection d'obstacles inattendus et hors-distribution (*Out-of-Distribution* – OoD) sur la chaussée. Dans le contexte critique de la conduite autonome, les réseaux de neurones de segmentation sémantique entraînés sur un vocabulaire fermé d'objets (route, voiture, piéton) échouent lorsqu'ils rencontrent des dangers imprévus (animaux, rochers, débris). Ce document détaille les objectifs commerciaux, les critères de succès, l'inventaire des ressources sur le jeu de données **RoadAnomaly**, la traduction technique en objectifs de Deep Learning, ainsi qu'un glossaire pédagogique exhaustif.

Contents

1 Introduction et Contexte du Domaine Métier **2**
- 1.1 La Problématique des Objets Hors-Distribution (OoD) . . . 2
- 1.2 Le Dataset d'Étude : RoadAnomaly . . . 2

2 Phase 1 CRISP-DM : Business Understanding **2**
- 2.1 Description du Problème et Solutions Actuelles . . . 2
- 2.2 Objectifs Commerciaux et Critères de Succès Métier . . . 2
- 2.3 Traduction en Objectifs de Deep Learning . . . 3
- 2.4 Inventaire des Ressources, Risques et Contraintes . . . 3

3 Glossaire Pédagogique des Termes de Recherche **4**

4 Feuille de Route et Recommandations de Lecture **4**

5 Références Bibliographiques **5**

1 Introduction et Contexte du Domaine Métier

La sécurité des **véhicules autonomes et connectés** (CAVs – *Connected and Autonomous Vehicles*) dépend de la fiabilité absolue de leur système de perception visuelle. Les modules de vision embarqués exploitent des algorithmes de **segmentation sémantique** fondés sur le Deep Learning pour analyser chaque image capturée par les caméras frontales et attribuer une étiquette à chaque pixel (ex. asphalte, piéton, véhicule, panneau de signalisation).

1.1 La Problématique des Objets Hors-Distribution (OoD)

En situation réelle de conduite, un véhicule fait face à une infinité de scénarios imprévisibles. Des objets non répertoriés dans les jeux de données d'apprentissage classiques (tels que Cityscapes) apparaissent régulièrement sur la route : animaux sauvages, rochers tombés de falaises, cargaisons perdues, matériel de chantier ou conteneurs. Sous l'hypothèse d'un « monde fermé » (*closed-set assumption*), les réseaux de neurones conventionnels tentent de classifier ces éléments inconnus dans l'une des catégories connues, souvent avec une **surconfiance excessive** (*overconfidence*). Par exemple, un chien sur la route peut être classifié à 98% de confiance comme une voiture ou de la route, conduisant le véhicule autonome à ne pas freiner ou à effectuer une manoeuvre dangereuse.

1.2 Le Dataset d'Étude : RoadAnomaly

Pour répondre à ce défi, le jeu de données **RoadAnomaly** a été conçu par Lis et al. (ICCV 2019). Il comporte 60 images réelles haute résolution (1280×720 pixels, généralement redimensionnées en 1024×512) collectées en ligne, présentant une grande diversité d'anomalies de tailles très différentes (animaux, rochers, pneus, poubelles, obstacles divers) situées sur la route ou à ses abords immédiats. Chaque image est accompagnée d'un masque d'annotation sémantique précis au niveau du pixel (*ground-truth mask*).

2 Phase 1 CRISP-DM : Business Understanding

La méthode **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) préconise de structurer le lancement de tout projet de Data Science en formalisant précisément les aspects métier et organisationnels.

2.1 Description du Problème et Solutions Actuelles

- **Problème Métier :** L'incapacité des systèmes actuels à détecter les obstacles imprévus crée un risque majeur d'accident corporel ou matériel.
- **Limites des Approches Actuelles :**
  1. *Probabilité Softmax Maximale (MSP) :* Méthode basique mesurant l'incertitude du réseau, mais qui échoue sur des images complexes où le réseau reste anormalement confiant sur l'inconnu.
  2. *Méthodes Basées sur la Reconstitution :* Utilisation d'autoencodeurs pour reconstruire l'image. Si l'objet est inconnu, la reconstruction échoue et la différence (erreur de reconstruction) signale l'anomalie. Cependant, ces méthodes produisent souvent des masques très bruités ou fragmentés.

2.2 Objectifs Commerciaux et Critères de Succès Métier

- **Objectif Commercial :** Garantir la sécurité critique des passagers et des usagers de la route en permettant au véhicule d'anticiper la présence de tout obstacle non identifié.

- **Critères de Succès Commercial :**
  - **Objectifs :** Localiser 100% des obstacles représentant un risque de collision sur la voie de circulation.
  - **Subjectifs :** Réduire le taux de fausses alarmes pour éviter les freinages intempestifs qui nuiraient au confort et à la confiance des passagers.

2.3 Traduction en Objectifs de Deep Learning

- **Tâche Technique :** Développer, implémenter et évaluer des architectures de Deep Learning (réseaux de neurones convolutifs, modèles de segmentation, autoencodeurs, transfer learning) pour générer une carte de score d'anomalie par pixel et isoler les masques d'objets.
- **Critères de Succès Technique :** L'évaluation repose sur des métriques standardisées :
  - **Intersection over Union (IoU) / Dice Score :** Mesure la précision géométrique du recouvrement entre le masque prédit et le masque réel.
  - **AuPRC (Area under Precision-Recall Curve) :** Mesure la capacité à détecter les pixels d'anomalies, très minoritaires par rapport aux pixels de fond.
  - **FPR95 (False Positive Rate at 95% TPR) :** Mesure le pourcentage de faux positifs lorsque le modèle détecte au moins 95% des vrais pixels d'anomalie (viser la valeur la plus basse possible).

2.4 Inventaire des Ressources, Risques et Contraintes

Table 1: Inventaire synthétique du projet de détection d'anomalies routières

Catégorie	Détails et Spécifications
Cadre du Projet	Module académique Deep Learning. Date limite de soumission : **8 Novembre 2026**.
Jeu de Données	**RoadAnomaly** (60 images réelles + masques au pixel). Complété par les benchmarks **RoadAnomaly21** et **RoadObstacle21** (SegmentMeIfYouCan).
Livrables Requis	1. Code Python / Notebook Jupyter propre, structuré et documenté. 2. Rapport technique justificatif détaillant l'exploration, la méthodologie et les résultats. 3. Visualisations expérimentales des prédictions (images originelles, masques réels et masques prédits).
Risques Identifiés	1. *Bruit et fragmentation :* Difficulté à fixer un seuil unique pour séparer les pixels normaux des anomalies. 2. *Surapprentissage :* Risque de dégrader la segmentation des classes normales (route, voiture) en forçant la détection OoD. 3. *Temps de calcul :* Modèles lourds nécessitant un compromis entre précision et vitesse d'exécution.
Plan de Secours	Utiliser un post-traitement des cartes de score ou un générateur de boîtes englobantes (*prompts*) combiné à un modèle de segmentation (approche type S2M).

3 Glossaire Pédagogique des Termes de Recherche

1. Concepts Métier et Méthodologiques

CRISP-DM : *Cross-Industry Standard Process for Data Mining*. Le guide méthodologique universel qui découpe un projet Data en 6 phases.

In-Distribution (ID) : Ensemble des données et concepts connus par le modèle.

Out-of-Distribution (OoD) : Tout élément ou objet totalement inconnu du modèle lors de son apprentissage.

Ground-Truth (Vérité Terrain) : L'image d'annotation produite à la main par des experts humains, servant de référence.

2. Architectures et Techniques de Deep Learning

Segmentation Sémantique : Technique consistant à classifier et colorier chaque pixel d'une image.

Logits & Softmax : Les *logits* sont les scores bruts numériques. La fonction *Softmax* les transforme en probabilités normalisées.

Autoencodeur : Réseau composé d'un encodeur et d'un décodeur. S'il tente de reconstruire un objet inconnu, l'erreur de reconstruction révèle l'anomalie.

Transfer Learning : Réutilisation d'un modèle pré-entraîné pour l'adapter à notre problème.

3. Métriques d'Évaluation Explicatives

IoU (Intersection over Union) : Pourcentage de chevauchement entre la surface prédite et la surface réelle :

$$\text{IoU} = \frac{\text{Surface de Chevauchement}}{\text{Surface Totale Couverte}}$$

Dice Score / F1-Score : Mesure équilibrée combinant Précision et Rappel :

$$\text{Dice} = \frac{2 \times \text{Vrais Positifs}}{2 \times \text{Vrais Positifs} + \text{Faux Positifs} + \text{Faux Négatifs}}$$

4 Feuille de Route et Recommandations de Lecture

Pour conduire à bien vos recherches et la mise en pratique du projet, voici la séquence recommandée pour l'étude des documents de votre corpus :

1. **Cadrage de l'épreuve :** Commencer par la consigne *Dear Students* pour assimiler la grille d'évaluation et la date limite du **8 Novembre 2026**.
2. **Cadre théorique métier :** Lire le document synthétique *CRISP-DM Overview* pour structurer la rédaction de votre rapport.
3. **Dataset et baseline de référence :** Étudier l'article fondateur de Lis et al. (ICCV 2019) sur le jeu de données **RoadAnomaly**.

4. **Benchmarks et évaluation :** Consulter l'article *SegmentMeIfYouCan* (Chan et al., 2021) pour maîtriser le calcul des métriques au niveau objet et pixel.

5. **État de l'art et avancées récentes :** Explorer les enquêtes récentes et approches de pointe (S2M, PixOOD, ProPETL).

5 Références Bibliographiques

References

[1] Lis, K., Nakka, K., Fua, P., & Salzmann, M. (2019). Detecting the Unexpected via Image Resynthesis. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 2152–2161.

[2] Chan, R., Lis, K., Uhlemeyer, S., Blum, H., Honari, S., Siegwart, R., Fua, P., Salzmann, M., & Rottmann, M. (2021). SegmentMeIfYouCan: A Benchmark for Anomaly Segmentation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 34, pp. 14751–14763.

[3] Zhao, W., Li, J., & Guo, Y. (2024). From Pixel to Mask: A Survey of Out-of-Distribution Segmentation. *arXiv preprint arXiv:2405.00000*.

[4] Authors. (2024). Segment Every Out-of-Distribution Object (S2M). In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

[5] Authors. (2024). PixOOD: Pixel-Level Out-of-Distribution Detection. *arXiv preprint arXiv:2405.19882v3*.

[6] IBM SPSS Modeler. (2026). *CRISP-DM Business Understanding Overview & Data Mining Life Cycle*.

[7] Deep Learning Module Instructors. (2026). *Deep Learning Assignment Brief: Road Anomaly Detection with RoadAnomaly Dataset*.