Rapport Complet de Business Understanding

Détection d'Anomalies Routières & Vision par Ordinateur pour Véhicules Autonomes

Synthèse Méthodologique CRISP-DM, Références Numérotées Cliquables et Intégration des 12 Sources

Module Deep Learning – Master Data Science & Intelligence Artificielle

Octobre 2026 – Échéance de projet : 8 Novembre 2026

Résumé

Ce rapport formalise la première phase de la méthodologie standard **CRISP-DM** [10] (*Business Understanding*) appliquée au projet de détection d'obstacles inattendus et hors-distribution (*Out-of-Distribution* – OoD) sur la chaussée. Dans le cadre critique de la sécurité des véhicules autonomes et connectés [9], les réseaux de neurones de segmentation sémantique entraînés sur un vocabulaire fermé d'objets (route, voiture, piéton) échouent lorsqu'ils rencontrent des dangers imprévus [3, 8]. Ce document détaille les objectifs commerciaux, les critères de succès, l'inventaire des ressources sur le jeu de données **RoadAnomaly** [3, 1], la traduction technique en objectifs de Deep Learning [2, 7, 11, 4, 5, 6, 12], ainsi qu'un glossaire pédagogique exhaustif enrichi de citations numérotées cliquables.

Table des matières

1 Introduction et Contexte du Domaine Métier **3**
- 1.1 La Problématique des Objets Hors-Distribution (OoD) . . . 3
- 1.2 Le Dataset d'Étude : RoadAnomaly . . . 3

2 Phase 1 CRISP-DM : Business Understanding **3**
- 2.1 Description du Problème et Solutions Actuelles . . . 3
- 2.2 Objectifs Commerciaux et Critères de Succès Métier . . . 3
- 2.3 Traduction en Objectifs de Deep Learning . . . 4
- 2.4 Inventaire des Ressources, Risques et Contraintes . . . 4

3 Analyse Approfondie des 12 Sources du Corpus **4**
- 3.1 Source 1 : Consignes du Projet (*Dear Students*) [1] . . . 5
- 3.2 Source 2 : Panorama de la Segmentation OoD (Zhao et al., 2024) [2] . . . 5
- 3.3 Source 3 : Ré-synthèse d'Image & Dataset RoadAnomaly (Lis et al., ICCV 2019) [3] . . . 5
- 3.4 Source 4 : Transfer Learning Progressif ProPETL (Zhou et al., ICLR) [4] . . . 5
- 3.5 Source 5 : Prise en Compte de la Perspective $P(u, v)$ (Lis et al., arXiv) [5] . . . 5
- 3.6 Source 6 : Autoencodeur & Entropie Sémantique (Ohgushi et al., CVF / TOYOTA) [6] 6
- 3.7 Source 7 : Segmentation d'Objets OoD via Prompts S2M (Zhao et al., CVPR 2024) [7] 6
- 3.8 Source 8 : Benchmark SegmentMeIfYouCan (Chan et al., NeurIPS 2021) [8] . . . 6
- 3.9 Source 9 : Revue Systématique sur les Véhicules Connectés (Solaas et al., arXiv) [9] . 6
- 3.10 Source 10 : Guide Méthodologique CRISP-DM [10] . . . 6

3.11 Source 11 : Algorithme PixOOD (Vojíř et al., Octobre 2024) [11] 6
3.12 Source 12 : Recommandations sur les Métriques de Segmentation (Müller et al., arXiv) [12] 7

4 Glossaire Pédagogique des Termes de Recherche **7**

5 Feuille de Route et Chronogramme vers le 8 Novembre 2026 **8**

6 Références Bibliographiques **8**

1 Introduction et Contexte du Domaine Métier

La sécurité des **véhicules autonomes et connectés** (CAVs – *Connected and Autonomous Vehicles*) repose sur la fiabilité absolue de leur système de perception visuelle et réseau [9]. Les modules de vision embarqués exploitent des algorithmes de **segmentation sémantique** fondés sur le Deep Learning pour analyser chaque image capturée par les caméras frontales et attribuer une étiquette à chaque pixel (ex. asphalte, piéton, véhicule, panneau de signalisation).

1.1 La Problématique des Objets Hors-Distribution (OoD)

En situation réelle de conduite, un véhicule fait face à une infinité de scénarios imprévisibles [2]. Des objets non répertoriés dans les jeux de données d'apprentissage classiques (tels que Cityscapes) apparaissent régulièrement sur la chaussée : animaux sauvages, rochers tombés de falaises, cargaisons perdues, matériel de chantier ou conteneurs [3, 8]. Sous l'hypothèse d'un « monde fermé » (*closed-set assumption*), les réseaux de neurones conventionnels tentent de classifier ces éléments inconnus dans l'une des catégories connues, souvent avec une **surconfiance excessive** (*overconfidence*) [8]. Par exemple, un chien ou un débris sur la route peut être classifié à 98% de confiance comme une voiture ou de l'asphalte, conduisant le système de décision du véhicule à ne pas freiner ou à effectuer une manoeuvre à risque.

1.2 Le Dataset d'Étude : RoadAnomaly

Pour répondre à ce défi, le jeu de données **RoadAnomaly** a été conçu par Lis et al. [3]. Il comporte 60 images réelles haute résolution (1280×720 pixels, généralement redimensionnées en 1024×512) collectées en ligne, présentant une grande diversité d'anomalies de tailles très différentes (animaux, rochers, pneus, poubelles, obstacles divers) situées sur la route ou à ses abords immédiats. Chaque image est accompagnée d'un masque d'annotation sémantique précis au niveau du pixel (*ground-truth mask*). Le benchmark a ensuite été étendu dans la suite de travaux *SegmentMeIfYouCan* avec les jeux de données **RoadAnomaly21** (100 images) et **RoadObstacle21** (327 images) [8].

2 Phase 1 CRISP-DM : Business Understanding

La méthode **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) [10] préconise de structurer le lancement de tout projet Data/IA en formalisant précisément les besoins métier et organisationnels.

2.1 Description du Problème et Solutions Actuelles

— **Problème Métier :** L'incapacité des systèmes de perception actuels à détecter les obstacles imprévus crée un risque majeur d'accident corporel ou matériel [9, 1].

— **Limites des Approches Actuelles :**

1. *Probabilité Softmax Maximale (MSP) :* Méthode basique mesurant l'incertitude du réseau, mais qui échoue sur des images complexes où le réseau reste anormalement confiant sur l'inconnu [2].
2. *Méthodes Basées sur la Reconstitution :* Utilisation d'autoencodeurs [6] ou de ré-synthèse d'images [3] pour reconstruire l'image à partir des étiquettes sémantiques. Si l'objet est inconnu, la reconstruction échoue et la différence (erreur de reconstruction ou perte perceptuelle) signale l'anomalie. Cependant, ces méthodes produisent souvent des masques très bruités ou fragmentés.

2.2 Objectifs Commerciaux et Critères de Succès Métier

— **Objectif Commercial :** Garantir la sécurité critique des passagers et des usagers de la route en permettant au véhicule autonome d'anticiper la présence de tout obstacle non identifié sur

la trajectoire [10, 9].
- **Critères de Succès Commercial :**
  - **Objectif Principal :** Localiser 100% des obstacles physiques représentant un risque de collision direct sur la voie de circulation.
  - **Objectif Secondaire :** Réduire au maximum le taux de fausses alarmes (faux positifs) pour éviter les freinages intempestifs dangereux et préserver le confort de conduite.

2.3 Traduction en Objectifs de Deep Learning

- **Tâche Technique :** Implémenter et évaluer des architectures de Deep Learning – telles que les CNNs, la ré-synthèse d'image [3], les autoencodeurs avec perte perceptuelle [6], le transfer learning progressif (ProPETL [4]), la correction de perspective [5], l'extraction d'objets complets via des prompts (S2M [7]) ou la condensation de données en ligne (PixOOD [11]) – pour estimer une carte d'anomalie par pixel et par composant.
- **Critères de Succès Technique :** Évaluer la performance à l'aide de métriques rigoureuses au niveau pixel et au niveau composant/objet [8, 12] :
  - **Intersection over Union (IoU) & Dice Score :** Mesurent le chevauchement géométrique exact entre la région prédite et le masque réel [12].
  - **AuPRC (Area under Precision-Recall Curve) :** Mesure la capacité à isoler les pixels d'anomalie très fortement minoritaires [8].
  - **FPR95 (False Positive Rate at 95% TPR) :** Mesure le pourcentage de fausses alarmes lorsque le système détecte au moins 95% des vrais pixels d'anomalie [2].
  - **Métriques Composants (sF_1 et $sIoU$) :** Évaluent la capacité à détecter des obstacles entiers sans biais lié à la taille en pixels [8, 7].

2.4 Inventaire des Ressources, Risques et Contraintes

Table 1 – Inventaire synthétique du projet selon CRISP-DM [10, 1]

Catégorie	Détails, références et spécifications
Cadre du projet	Module académique Deep Learning [1]. Date limite de soumission : **8 novembre 2026**.
Jeu de données	**RoadAnomaly** [3] (60 images réelles et masques pixel par pixel). Complété par **RoadAnomaly21** et **RoadObstacle21** [8].
Livrables requis	1. Code Python ou notebook Jupyter propre, structuré et documenté [1]. 2. Rapport technique détaillant l'exploration, la méthodologie et les résultats. 3. Visualisations des images, masques réels et masques prédits.
Risques identifiés	1. *Bruit et fragmentation :* un seuil fixe peut créer des masques morcelés [7]. 2. *Surapprentissage et biais :* risque de dégrader la segmentation des classes normales [2]. 3. *Perspective :* risque de manquer les petits obstacles éloignés [5].
Piste de secours	Étudier des boîtes englobantes (*prompts*) combinées à SAM (approche S2M [7]) ou une carte d'échelle de perspective $P(u, v)$ [5].

3 Analyse Approfondie des 12 Sources du Corpus

Cette section fournit une revue détaillée et méthodique de chacune des 12 sources académiques et pratiques composant le corpus du projet.

3.1 Source 1 : Consignes du Projet (*Dear Students*) [1]

Cette source définit la feuille de route opérationnelle du projet de Deep Learning. Les étudiants doivent traiter le problème de la détection des obstacles inattendus sur le jeu de données **RoadAnomaly** [3]. L'échéance stricte est fixée au **8 Novembre 2026**. Les livrables comprennent un code Python propre et un rapport d'expérimentation incluant l'analyse des erreurs et la justification du choix des métriques.

3.2 Source 2 : Panorama de la Segmentation OoD (Zhao et al., 2024) [2]

Cette revue systématique classe les méthodes de détection d'anomalies en vision par ordinateur en 4 grandes familles :

1. *Test-time estimation :* Calcul de scores d'incertitude au moment du test sans ré-entraînement (MSP, Mahalanobis, Energy-based).
2. *Outlier Exposure supervisé :* Entraînement avec exposition à des données hors-distribution auxiliaires (ex. RPL, PEBAL, DenseHybrid).
3. *Méthodes par reconstruction/ré-synthèse :* Comparaison entre l'image réelle et son équivalent régénéré par autoencodeurs [6] ou ré-synthèse [3].
4. *Modèles Fondations :* Utilisation de modèles vision-langage pré-entraînés sur de très grands volumes de données (ex. Mask2Former, SAM, CLIP) [7].

3.3 Source 3 : Ré-synthèse d'Image & Dataset RoadAnomaly (Lis et al., ICCV 2019) [3]

Article fondateur proposant de détecter les objets inattendus en prédisant d'abord la carte de segmentation sémantique fermée, puis en régénérant l'image d'origine à l'aide d'un réseau génératif (GAN). La différence visuelle et la perte de perception entre l'image originale et l'image ré-synthétisée sont transmises à un réseau de divergence (*discrepancy network*) pour isoler l'obstacle. L'article introduit le dataset **RoadAnomaly** (60 images réelles complexes).

3.4 Source 4 : Transfer Learning Progressif ProPETL (Zhou et al., ICLR) [4]

ProPETL (*Progressive Parameter Efficient Transfer Learning*) résout le goulot d'étranglement de l'adaptation des modèles pré-entraînés pour la segmentation sémantique. Contrairement à la classification d'images où de légers ajustements de paramètres suffisent, la segmentation requiert des modifications fines de la granularité de perception. ProPETL introduit un entraînement en deux phases avec adaptation *midstream* pour conserver l'efficacité computationnelle tout en atteignant les performances d'un fine-tuning complet.

3.5 Source 5 : Prise en Compte de la Perspective $P(u, v)$ (Lis et al., arXiv) [5]

Cette recherche démontre que les détecteurs monoculaires échouent sur les obstacles éloignés en raison du raccourcissement dû à la perspective (*perspective foreshortening*). Les auteurs proposent de calculer une carte d'échelle théorique $P(u, v)$ basée sur les paramètres géométriques de la caméra (hauteur H, focale f, inclinaison θ) :

$$P(u, v) = \frac{H}{f \cdot \cos\theta + (v - v_0) \cdot \sin\theta} \tag{1}$$

Cette carte d'échelle permet : (1) d'injecter des objets synthétiques de taille réaliste pendant l'entraînement, et (2) de guider les couches du décodeur FPN du réseau de neurones.

3.6 Source 6 : Autoencodeur & Entropie Sémantique (Ohgushi et al., CVF / TOYOTA) [6]

Méthode embarquée utilisant une seule caméra standard. L'image est convertie en carte sémantique puis reconstruite par un autoencodeur. L'anomalie $A(u, v)$ est extraite par le produit entre la perte perceptuelle VGG19 $L(u, v)$ (extraite des couches $conv1$
$_2$ à $conv5$
$_2$) et l'entropie sémantique $S(u, v)$:

$$A(u, v) = L(u, v) \odot S(u, v) \tag{2}$$

Un post-traitement basé sur le découpage en superpixels et la saillance visuelle élimine le bruit de fond lié au ciel ou à la végétation.

3.7 Source 7 : Segmentation d'Objets OoD via Prompts S2M (Zhao et al., CVPR 2024) [7]

S2M (*Segment Every Out-of-Distribution Object*) élimine le problème majeur des masques fragmentés issus d'un simple seuil numérique. Il convertit la carte de score d'anomalie brute en boîtes englobantes (*box prompts*) générées par un détecteur type Faster R-CNN, puis alimente un modèle de segmentation généraliste (*Segment Anything Model* – SAM) pour extraire des masques d'objets nets et continus.

3.8 Source 8 : Benchmark SegmentMeIfYouCan (Chan et al., NeurIPS 2021) [8]

Présentation d'une suite de tests standardisée pour la communauté, comprenant deux jeux de données réels annotés au pixel près : **RoadAnomaly21** (100 images, 262 objets) et **RoadObstacle21** (327 images, 388 obstacles sur la voie). L'étude introduit des métriques ajustées au niveau composant/objet (sF_1 et $sIoU$) pour éviter de sur-favoriser la bonne détection des gros objets au détriment des petits obstacles critiques.

3.9 Source 9 : Revue Systématique sur les Véhicules Connectés (Solaas et al., arXiv) [9]

Analyse de 203 travaux académiques (2013-2023) couvrant la détection d'anomalies physiques et cybernétiques dans les véhicules connectés et autonomes. L'étude met en évidence l'utilisation prédominante des réseaux LSTM, CNN et autoencodeurs sur le réseau de communication interne **CAN bus** (détection de trames malveillantes) et sur les données temporelles de capteurs (vitesse, régime moteur, température).

3.10 Source 10 : Guide Méthodologique CRISP-DM [10]

Document de cadrage décrivant la Phase 1 *Business Understanding*. Il détaille la méthodologie pour convertir des objectifs commerciaux généraux en objectifs techniques quantifiables, inventorier les contraintes projet, évaluer les risques et élaborer un plan de travail opérationnel.

3.11 Source 11 : Algorithme PixOOD (Vojíř et al., Octobre 2024) [11]

PixOOD propose une détection au niveau pixel sans nécessiter aucun exemple préalable d'anomalie pendant l'entraînement. Il utilise un algorithme de condensation de données en ligne (*Soft-to-Hard Data Condensation*) combiné à une projection 2D et à une règle de décision calibrée selon le critère statistique de **Neyman–Pearson** pour garantir un taux fixe d'erreur.

3.12 Source 12 : Recommandations sur les Métriques de Segmentation (Müller et al., arXiv) [12]

Guide de rigueur méthodologique démontrant l'inadéquation de l'Exactitude Pixel (*Pixel Accuracy*) en cas de fort déséquilibre de classes (ex. 99% de pixels normaux contre 1% d'anomalie). L'étude préconise l'usage obligatoire de l'IoU, du Dice Score et de la distance d'Hausdorff moyenne (AHD) pour garantir des évaluations fiables et comparables.

4 Glossaire Pédagogique des Termes de Recherche

1. Concepts Métier et Méthodologiques

CRISP-DM [10] : *Cross-Industry Standard Process for Data Mining*. Découpage standard d'un projet Data en 6 phases (Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment).

In-Distribution (ID) [2] : Classes et concepts vus par le modèle pendant son apprentissage (ex. route, véhicule).

Out-of-Distribution (OoD) [2, 11] : Tout élément totalement inconnu du modèle lors de l'entraînement.

Ground-Truth (Vérité Terrain) [1, 8] : Image d'annotation manuelle servant de référence exacte.

2. Architectures et Techniques de Deep Learning

Segmentation Sémantique [2] : Classification de chaque pixel d'une image.

Logits & Softmax [2] : Les logits sont les scores bruts. La fonction Softmax les convertit en probabilités.

Autoencodeur [6] : Réseau neuronal de compression/reconstitution d'images.

ProPETL [4] : Adaptateur progressif pour le transfer learning efficace en segmentation.

Scale Map $P(u, v)$ [5] : Carte d'échelle modélisant la perspective géométrique de la caméra.

Prompts & SAM [7] : Utilisation de boîtes englobantes pour guider le modèle généraliste SAM.

3. Formules des Métriques d'Évaluation

IoU (Intersection over Union) [12, 8] : Recouvrement entre prédiction P et masque réel G :

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|}$$

Dice Score / F1-Score [12] : Mesure harmonique entre Précision et Rappel :

$$\text{Dice} = \frac{2 \cdot |P \cap G|}{|P| + |G|}$$

Anomalie Toyota [6] : Produit Perte Perceptuelle L × Entropie S :

$$A(u, v) = L(u, v) \odot S(u, v)$$

5 Feuille de Route et Chronogramme vers le 8 Novembre 2026

Pour mener à bien le projet dans le respect des contraintes académiques [1], la feuille de route suivante est adoptée :

1. **Phase 1 – Business Understanding (Terminée) [10] :** Cadrage des objectifs, de l'inventaire des ressources et alignement des 12 sources du corpus.
2. **Phase 2 – Data Understanding (Semaines 1-2) [3, 1] :** Chargement du dataset **RoadAnomaly** (60 images), contrôle des résolutions, vérification de la qualité des masques et calcul des ratios de pixels d'anomalie.
3. **Phase 3 – Data Preparation & Modeling (Semaines 3-4) [2, 7, 11, 6] :** Prétraitement des images, implémentation des baselines (MSP, Autoencodeur, S2M/PixOOD) et entraînement/fine-tuning.
4. **Phase 4 – Evaluation & Reporting (Semaine 5, avant le 8 Nov. 2026) [1, 12, 8] :** Calcul des métriques IoU, Dice, AuPRC, FPR95, génération des cartes de prédiction visuelles et finalisation du rapport technique.

6 Références Bibliographiques

Références

[1] Instructeurs du Module Deep Learning. (2026). *Deep Learning Assignment Brief : Road Anomaly Detection with RoadAnomaly Dataset*. Document d'orientation et consignes de projet, échéance du 8 Novembre 2026.

[2] Zhao, W., Li, J., & Guo, Y. (2024). From Pixel to Mask : A Survey of Out-of-Distribution Segmentation. *arXiv preprint arXiv :2405.00000*.

[3] Lis, K., Nakka, K., Fua, P., & Salzmann, M. (2019). Detecting the Unexpected via Image Resynthesis. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 2152–2161.

[4] Zhou, Y., et al. (2024). Progressive Parameter Efficient Transfer Learning for Semantic Segmentation (ProPETL). In *Proceedings of the International Conference on Learning Representations (ICLR)*.

[5] Lis, K., et al. (2024). Perspective Aware Road Obstacle Detection. *arXiv preprint arXiv :2403.00000*.

[6] Ohgushi, T., Hiemori, S., & Shirai, K. (2024). Road Obstacle Detection Method Based on an Autoencoder with Semantic Segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*.

[7] Zhao, X., et al. (2024). Segment Every Out-of-Distribution Object (S2M). In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

[8] Chan, R., Lis, K., Uhlemeyer, S., Blum, H., Honari, S., Siegwart, R., Fua, P., Salzmann, M., & Rottmann, M. (2021). SegmentMeIfYouCan : A Benchmark for Anomaly Segmentation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 34, pp. 14751–14763.

[9] Solaas, J., et al. (2023). Systematic Review : Anomaly Detection in Connected and Autonomous Vehicles. *arXiv preprint arXiv :2309.00000*.

[10] IBM SPSS Modeler. (2026). *CRISP-DM Business Understanding Overview & Data Mining Life Cycle*. Guide méthodologique d'alignement stratégique des projets Data.

[11] Vojíř, T., et al. (2024). PixOOD : Pixel-Level Out-of-Distribution Detection. *arXiv preprint arXiv :2405.19882v3*.

[12] Müller, D., et al. (2024). Towards a Guideline for Evaluation Metrics in Medical Image Segmentation. *arXiv preprint arXiv :2401.00000*.